

ĐỀ XUẤT NGHIÊN CỨU: CHARACTERISTIC SPECTRAL TRANSFORM CHO CHUNG CẤT TRI THỨC MÔ HÌNH NGÔN NGỮ

Anonymous authors

Paper under double-blind review

ABSTRACT

Đề xuất này trình bày Characteristic Spectral Transform (CST), một hàm mất mát phụ trợ dùng để truyền hình học biểu diễn từ mô hình giáo viên sang mô hình học sinh. Thay vì ép hai hidden state bằng nhau theo từng tọa độ, học một projector đối chiều, hoặc so trực tiếp các trị riêng, CST mô tả hình học của hidden state bằng đường cong $\Phi_H(\gamma) = \log \det(I + \gamma G_H)$ tại nhiều giá trị $\gamma > 0$. G_H là ma trận Gram đã trừ trung bình và chuẩn hóa năng lượng. Vì vậy, hai mô hình có hidden width khác nhau vẫn so sánh được bằng các số vô hướng. Trong đường train, log-determinant được tính bằng Cholesky theo batch, không sử dụng SVD hay eigendecomposition. Tài liệu giải thích từng công thức, thuật toán, độ phức tạp, cấu hình thực nghiệm và cách diễn giải kết quả ban đầu.

1 MỤC TIÊU VÀ CÂU HỎI NGHIÊN CỨU

Chung cất tri thức (knowledge distillation, KD) thường yêu cầu mô hình học sinh khớp phân phối đầu ra của mô hình giáo viên. Với một token, nếu z_s, z_t là logit của student và teacher, một dạng loss đầu ra là

$$\mathcal{L}_{KD} = D(\text{softmax}(z_s/T), \text{softmax}(z_t/T)), \quad (1)$$

trong đó D có thể là KL, skew-KL hoặc một divergence khác và T là nhiệt độ. Loss này trả lời câu hỏi “student có dự đoán giống teacher không?”, nhưng không trực tiếp trả lời câu hỏi “student có tổ chức biểu diễn trung gian giống teacher không?”.

Đề xuất đặt ra ba câu hỏi:

1. Có thể truyền cấu trúc phổ của hidden state mà không cần hai hidden width bằng nhau hay không?
2. Có thể tránh projector học được, teacher centroids, SVD và eigendecomposition trong đường train hay không?
3. Có thể làm điều đó với overhead đủ nhỏ cho on-policy KD hay không?

Mục tiêu cuối cùng là

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{KD} + \lambda_{\text{CST}} \mathcal{L}_{\text{CST}} \quad (2)$$

và giữ nguyên toàn bộ loss KD đầu ra hiện có.

2 KÝ HIỆU VÀ DỮ LIỆU ĐẦU VÀO

Xét một minibatch sau khi student đã sinh response. Tại một layer, gom hidden state của các response token hợp lệ thành

$$H \in \mathbb{R}^{m \times d}. \quad (3)$$

Ở đây:

- m là số token được chọn; cấu hình mặc định là $m \leq 64$;
- d là hidden width, ví dụ student và teacher có thể lần lượt là $d_s = 1536$ và $d_t = 5120$;
- mỗi hàng $H_{i,:}$ là biểu diễn của một token;
- teacher và student dùng đúng cùng vị trí token, nhưng không cần cùng số chiều đặc trưng.

Mask response lấy trực tiếp từ label:

$$\mathcal{I} = \{i : \text{label}_i \neq -100\}. \quad (4)$$

Nếu $|\mathcal{I}| > m_{\max}$, ta lấy ngẫu nhiên một tập con một lần trong mỗi training step. Tập chỉ số đó được dùng chung cho mọi layer, student và teacher.

3 TỪ HIDDEN STATE TỚI HÌNH HỌC CHUẨN HÓA

3.1 BƯỚC 1: TRỪ TRUNG BÌNH THEO TOKEN

Vector trung bình của layer là

$$\bar{h} = \frac{1}{m} \sum_{i=1}^m H_{i,:} \in \mathbb{R}^d. \quad (5)$$

Hidden state sau khi center:

$$X = H - \mathbf{1}\bar{h}^\top \in \mathbb{R}^{m \times d}. \quad (6)$$

Thao tác này loại bỏ phép tịnh tiến chung. Nếu mọi token cùng được cộng một vector b , tức $H' = H + \mathbf{1}b^\top$, thì $X' = X$.

3.2 BƯỚC 2: TÍNH TỔNG NĂNG LƯỢNG

$$e = \|X\|_F^2 = \sum_{i=1}^m \sum_{k=1}^d X_{ik}^2. \quad (7)$$

Nếu $e \leq \epsilon$, layer gần như hằng theo token và không chứa hình học đáng tin cậy; implementation bỏ qua layer này để tránh chia cho số gần zero.

3.3 BƯỚC 3: MA TRẬN GRAM TOKEN

$$G_H = \frac{XX^\top}{e + \epsilon} \in \mathbb{R}^{m \times m}. \quad (8)$$

Phần tử $(G_H)_{ij}$ đo inner product chuẩn hóa giữa token i và token j . Ma trận này là positive semidefinite (PSD), và khi $e \gg \epsilon$:

$$\text{Tr}(G_H) = \frac{\text{Tr}(XX^\top)}{e + \epsilon} \approx 1. \quad (9)$$

Do đó G_H giữ lại *cách năng lượng được phân bố giữa các hướng*, nhưng loại bỏ độ lớn tổng thể.

Ba bất biến quan trọng là

$$G_{H+\mathbf{1}b^\top} = G_H \quad (\text{tịnh tiến}), \quad (10)$$

$$G_{aH} = G_H, \quad a \neq 0 \quad (\text{scale đẳng hướng}), \quad (11)$$

$$G_{HQ} = G_H, \quad QQ^\top = I \quad (\text{xoay hệ tọa độ}). \quad (12)$$

Đây là lý do CST không cần học ánh xạ tọa độ từ student sang teacher.

4 CHARACTERISTIC SPECTRAL TRANSFORM

4.1 ĐỊNH NGHĨA TRUNG TÂM

Với một scale $\gamma > 0$, định nghĩa

$$\Phi_H(\gamma) = \log \det(I + \gamma G_H). \quad (13)$$

Vì $G_H \succeq 0$, mọi trị riêng của $I + \gamma G_H$ lớn hơn hoặc bằng 1; log-determinant vì vậy hữu hạn và không âm.

Nếu chỉ dùng để phân tích, gọi $p_1, \dots, p_r$ là các trị riêng dương của G_H . Khi đó

$$\Phi_H(\gamma) = \sum_{i=1}^r \log(1 + \gamma p_i). \quad (14)$$

Công thức 14 giải thích ý nghĩa phổ, nhưng implementation train **không tính** p_i .

4.2 TẠI SAO CẦN NHIỀU GIÁ TRỊ γ ?

Giả sử hai phổ đều có tổng bằng 1:

$$p^{(A)} = (0.5, 0.5), \quad (15)$$

$$p^{(B)} = (0.9, 0.1). \quad (16)$$

Ở scale nhỏ, khai triển Taylor cho ta

$$\Phi_H(\gamma) = \gamma \text{Tr}(G_H) - \frac{\gamma^2}{2} \text{Tr}(G_H^2) + O(\gamma^3). \quad (17)$$

Vì trace gần 1, số hạng bậc nhất của mọi representation gần giống nhau. Sự khác biệt bắt đầu rõ ở

$$\text{Tr}(G_H^2) = \sum_i p_i^2, \quad (18)$$

đại lượng đo mức tập trung phổ. Với ví dụ trên, giá trị này lần lượt là 0.5 và 0.82. Scale lớn hơn tiếp tục cung cấp thông tin về các moment bậc cao và số hướng hoạt động. Vì vậy một γ duy nhất có thể chỉ nhìn thấy một phần hình học; nhiều γ mô tả cả một đường cong đặc trưng.

4.3 TÍNH ĐẶC TRƯNG CỦA TRANSFORM

Đạo hàm theo scale là

$$\Phi'_H(\gamma) = \sum_{i=1}^r \frac{p_i}{1 + \gamma p_i}. \quad (19)$$

Về phải là một hàm hữu tỉ; các pole tại $-1/p_i$ xác định các trị riêng dương. Do đó, với phổ hữu hạn, nếu hai transform bằng nhau trên một khoảng γ mở thì hai normalized spectrum bằng nhau, kể cả multiplicity. Trong train ta không quan sát cả khoảng liên tục mà dùng Monte Carlo tại các scale mới qua mỗi step.

5 LOSS CST NHIỀU SCALE VÀ NHIỀU LAYER

Lấy log-uniform để mọi bậc độ lớn có xác suất như nhau:

$$u_j \sim \mathcal{U}(\log \gamma_{\min}, \log \gamma_{\max}), \quad (20)$$

$$\gamma_j = \exp(u_j), \quad j = 1, \dots, q. \quad (21)$$

Student và teacher bắt buộc dùng cùng γ_j . Loss tại cặp layer ℓ :

$$\mathcal{L}_{\text{CST}}^{(\ell)} = \frac{1}{q} \sum_{j=1}^q \left(\Phi_{H_s^{(\ell_s)}}(\gamma_j) - \text{stopgrad} \left[\Phi_{H_t^{(\ell_t)}}(\gamma_j) \right] \right)^2. \quad (22)$$

Với n cặp layer:

$$\mathcal{L}_{\text{CST}} = \frac{1}{n} \sum_{\ell=1}^n \mathcal{L}_{\text{CST}}^{(\ell)}. \quad (23)$$

Ký hiệu stop-gradient có hai ý nghĩa thực tế: teacher chạy dưới `no_grad`, và gradient của Equation 2 chỉ cập nhật student. CST cũng không sinh thêm module nào ở inference.

6 TÍNH LOG-DETERMINANT MÀ KHÔNG EIG/SVD

6.1 CHỌN KHÔNG GIAN DETERMINANT NHỎ HƠN

Thông thường $m = 64 \ll d$, nên dùng Gram token $XX^\top$ kích thước 64×64 . Nếu có trường hợp $d < m$, định lý determinant Sylvester cho phép

$$\det(I_m + \gamma XX^\top / e) = \det(I_d + \gamma X^\top X / e). \quad (24)$$

Vì vậy luôn chọn

$$r = \min(m, d), \quad B \in \mathbb{R}^{r \times r}. \quad (25)$$

6.2 DÙNG MỘT GRAM CHO MỌI GAMMA

Mỗi layer chỉ tính một lần

$$B = \frac{XX^\top}{e + \epsilon} \quad \text{hoặc} \quad B = \frac{X^\top X}{e + \epsilon}. \quad (26)$$

Sau đó broadcast toàn bộ q scale:

$$A = I_{[1,r,r]} + \text{gamma}_{[q,1,1]} B_{[1,r,r]} \in \mathbb{R}^{q \times r \times r}. \quad (27)$$

Không được tính lại $XX^\top$ bên trong vòng lặp gamma.

6.3 BATCHED CHOLESKY

Với từng $A_j \succ 0$:

$$A_j = L_j L_j^\top, \quad (28)$$

$$\log \det(A_j) = 2 \sum_{k=1}^r \log(L_j)_{kk}. \quad (29)$$

Một lệnh `torch.linalg.cholesky_ex(A)` xử lý cả batch q . Mọi phép tính phổ chạy float32 dù forward chính là fp16/bf16. Gram được symmetrize:

$$B \leftarrow \frac{1}{2}(B + B^\top). \quad (30)$$

Nếu Cholesky hiếm khi thất bại do sai số số học, retry một lần với $A_j + 10^{-6}I$.

6.4 ĐỘ PHỨC TẠP

Chi phí mỗi layer xấp xỉ

$$O(mdr) + O(qr^3), \quad r = \min(m, d). \quad (31)$$

Với $m = r = 64$, $q = 2$, $n = 4$, phần determinant rất nhỏ so với forward teacher 14B. Log thực nghiệm đo khoảng 2.2ms cho CST kernel, trong khi một optimizer step đầy đủ của on-policy pipeline khoảng 22.6 giây. Con số 2.2ms không bao gồm toàn bộ chi phí giữ hidden state, nên báo cáo cuối cùng vẫn cần đo end-to-end so với output-KD baseline.

Table 1: Phân biệt ba representation objective.

	NuNo	RPT	CST
Đối tượng	Nuclear norm có centroid	Profile tích lũy trị riêng	$\log \det(I + \gamma G)$
Projector	Có	Không	Không
Centroid	Có	Không	Không
Eig/SVD khi train	Tránh bằng Newton-Schulz	Phân rã trị riêng	Không
Nhiều scale	Không	Không	Có

Table 2: Cấu hình Qwen và CST hiện tại.

Teacher $\rightarrow$ student	Qwen2.5-14B $\rightarrow$ 1.5B
Global batch / epochs	64 / 2
Learning rate / scheduler	5×10^{-6} / cosine
Warmup / max length	0.1 / 1024
Số layer / depth range	4 / [0.20, 0.85]
Token tối đa m	64
Số gamma q	2
Khoảng gamma	$[10^{-2}, 10^2]$, log-uniform
Khoảng cách transform	squared ℓ_2
λ_{CST}	0.003

7 CST KHÁC GÌ NuNo VÀ RPT?

RPT là baseline phân tích hợp lệ nhưng không phải cách triển khai CST. Không được đơn giản hóa Equation 13 thành loss khớp trực tiếp eigenvalue. Tương tự, projector đã tồn tại cho NuNo không được tái sử dụng trong CST path.

8 CẤU HÌNH THỰC NGHIỆM ĐỀ XUẤT

Tại đầu run, raw CST loss thường nằm khoảng 30–65, còn output-KD khoảng 1.2–1.4. Nếu dùng nhằm weight 0.2 của NuNo, thành phần CST có thể lớn khoảng 12 và áp đảo KD. Với $\lambda_{\text{CST}} = 0.003$, contribution điển hình là

$$0.003 \times 60 = 0.18, \quad (32)$$

tức khoảng 10–15% output loss. Vì hai loss có scale khác nhau, không nên đồng nhất λ_{CST} với λ_{NNM} .

Grid tune đề xuất:

$$\lambda_{\text{CST}} \in \{0.001, 0.003, 0.01, 0.03\}, \quad (33)$$

$$m \in \{32, 64, 128\}, \quad (34)$$

$$q \in \{1, 2, 4\}, \quad (35)$$

$$n \in \{2, 4\}. \quad (36)$$

Chỉ thay một trục trong mỗi ablation và giữ seed, dữ liệu, output-KD, decoding và evaluator cố định.

9 KẾT QUẢ BAN ĐẦU VÀ CÁCH ĐỌC ĐÚNG

Run hiện có dùng 10K training examples, hai epochs, trong khi bảng tham chiếu NuNo dùng khoảng 78K examples. Vì ngân sách chưa bằng nhau, đây là kết quả pilot chứ chưa phải chứng minh CST hơn phương pháp khác.

CST 10K tăng 5.3 điểm so với base student tham chiếu và gần bằng NuNo trên GSM8K, GSM-Plus, SciQ và STEM. Nó cao hơn ở MBPP và Pro-Math nhưng thấp hơn ở BBH. Cột MATH cần giải thích riêng.

Table 3: Accuracy (%) trên Qwen2.5-14B $\rightarrow$ 1.5B. Các dòng tham chiếu lấy từ manuscript NuNo; CST dùng 10K examples. MATH trong average dùng exact-match để gần bằng cũ nhất có thể.

Method	GSM8K	GSM+	MATH	MBPP	SciQ	STEM	Pro-Math	BBH	Avg.
Student tham chiếu	57.1	38.8	16.9	38.4	85.5	49.5	34.4	36.5	44.6
NuNo tham chiếu	65.2	46.8	32.2	44.4	86.2	51.7	42.0	44.9	51.7
CST, 10K	65.58	46.79	14.92	46.80	86.90	51.95	44.49	41.87	49.91

Harness hiện tại trả về hai metric trên cùng 5,000 generation:

$$\text{exact_match} = 14.92, \quad (37)$$

$$\text{math_verify} = 45.06. \quad (38)$$

Trong 4,454 sample file đã kiểm tra, confusion giữa hai metric là:

Exact	Verify	Số mẫu
0	0	2,372
0	1	1,409
1	1	669
1	0	4

Nhiều câu trong nhóm $(0, 1)$ có đáp án toán đúng và được đóng khung `\boxed{...}`, nhưng thiếu đúng chuỗi “Final Answer” mà exact parser mong đợi. Vì vậy 14.92 bị ảnh hưởng mạnh bởi format; ngược lại, không được so thẳng 45.06 với MATH 32.2 của một evaluator version khác. Cách so sánh hợp lệ là chạy CST, NuNo, RPT và output-KD bằng cùng container, rồi báo cả exact và symbolic verification.

10 KẾ HOẠCH HOÀN THIÊN PAPER

Thí nghiệm bắt buộc.

1. Chạy đủ khoảng 78K mẫu cho Qwen, ít nhất ba seed cho cấu hình chính.
2. Train lại output-KD, NuNo, RPT và CST với cùng data order và budget.
3. Đóng băng phiên bản Transformers, lm-eval, vLLM, task YAML và prompt.
4. Chạy cặp Gemma2-9B $\rightarrow$ 2B để kiểm tra khả năng tổng quát.
5. Báo wall-clock, peak memory và throughput end-to-end, không chỉ CST kernel time.

Ablation quan trọng. Ngoài m, q, n, λ , cần so sánh center và không center; log-uniform với fixed grid; squared ℓ_2 với smooth- ℓ_1 ; shared gamma với gamma khác nhau (negative control); và shared token indices với sampling độc lập (negative control). Hai negative control dự kiến kém hơn vì phá tính so sánh trực tiếp.

Phân tích representation. Eigendecomposition chỉ được dùng offline để vẽ effective rank, entropy và rank profile theo layer. Nó là công cụ kiểm tra CST có thực sự thay đổi geometry hay không, không được đưa trở lại training objective.

11 RỦI RO VÀ GIỚI HẠN

- Hai gamma mỗi step chỉ là estimator thừa của một đường cong liên tục.
- Global token sampling có thể trộn các sequence dài/ngắn không đều.
- Loss scale phụ thuộc khoảng gamma và cần tune lại khi đổi cấu hình.
- Kết quả hiện tại mới có một seed, một model pair và 10K examples.

- Benchmark accuracy không đo safety; distillation có thể sao chép bias và lỗi của teacher.

12 KẾT LUẬN ĐỀ XUẤT

CST biến bài toán khớp geometry thành bài toán khớp một hàm vô hướng nhiều scale. Trọng tâm phương pháp không phải eigenvalue matching, mà là objective transform-level

$$\Phi_H(\gamma) = \log \det(I + \gamma G_H).$$

Thiết kế này giải quyết tự nhiên hidden-width mismatch, loại bỏ projector và teacher centroid, đồng thời có đường tính toán Cholesky nhỏ và ổn định. Kết quả 10K ban đầu đủ để biện minh cho full-budget study, nhưng mọi tuyên bố vượt NuNo phải chờ controlled reproduction với evaluator cố định.

A PSEUDOCODE GẦN VỚI IMPLEMENTATION

```

idx = response_mask.nonzero()
idx = random_subset(idx, max_tokens=64) # một lần mỗi step
gamma = exp(uniform(log(1e-2), log(1e2), size=[2]))

losses = []
for s_layer, t_layer in layer_pairs:
    Xs = center(student_hidden[s_layer][idx]).float()
    Xt = center(teacher_hidden[t_layer][idx]).float().detach()
    Bs = smaller_gram(Xs) / (frobenius_sq(Xs) + eps)
    Bt = smaller_gram(Xt) / (frobenius_sq(Xt) + eps)
    As = I[None] + gamma[:, None, None] * Bs[None]
    At = I[None] + gamma[:, None, None] * Bt[None]
    phi_s = 2 * log(diag(cholesky(As))).sum(-1)
    phi_t = 2 * log(diag(cholesky(At))).sum(-1)
    losses.append(mean((phi_s - stopgrad(phi_t)) ** 2))

L_cst = mean(losses)
L_total = L_output_kd + lambda_cst * L_cst

```

B CHECKLIST KIỂM TRA IMPLEMENTATION

- Không có projector trong CST path.
- Không có centroid, K-means hay random projection.
- Không gọi SVD/eigvalsh trong main loss.
- Teacher và student dùng cùng token indices, layer mapping và gamma.
- Teacher transform stop-gradient.
- Gram chỉ tính một lần mỗi layer rồi dùng lại cho mọi gamma.
- Gamma được batch trong một Cholesky call.
- Dùng determinant space nhỏ hơn và float32.
- Degenerate layer được skip an toàn.
- Unit tests kiểm tra invariance, Sylvester, slogdet reference, gradient, teacher stop-gradient và projector-free dispatch.